

# Theorie des Langages

Matthew Coyle

January 10, 2018

## 1 Introduction

Les langages formels ont été étudiés par:

- les informaticiens: langages de programmation
- les linguistes: langues naturelles

Langages formels: Points communs:

Chaque langage est un ensemble d'éléments appelés mots ou "chaînes".

Chaque chaîne est une suite de symboles pris parmi un ensemble fini de symboles.

Chaque chaîne est de longueur finie.

On étudie des modèles pour représenter de manière finie des langages:

automates finis

expressions régulières

grammaires formelles

Applications pratiques:

Recherche de "motifs" dans les fichiers

traitement de texte

modélisation de circuits

modélisation de machines à états

Compilation de langages de programmation

un alphabet est un ensemble fini, non vide, de symboles. On le note généralement  $\Sigma$ .

Exemple d'alphabets:

$\Sigma_{entiers} = \{0,1,2,3,4,5,6,7,8,9\}$

$\Sigma_{mots} = \{a,b,c,\dots,z,',-\}$

$\Sigma_{ident} = \{a,\dots,z,A,\dots,Z,0,\dots,9,-\}$

$\Sigma_{prog} = \{int, float, bool, while, i, toto, a, \dots\}$

Un mot ou une chaîne  $w$  formée sur un alphabet est une suite finie  $s_1s_2\dots s_n$  de symboles de cet alphabet

La concatenation de deux chaines  $u$  et  $v$ , notée  $u.v$  ou  $uv$  est la chaine obtenue en ecrivant les symboles de  $u$  suivis de ceux de  $v$ .

si  $u = a_1a_2...a_n$  et  $v = b_1b_2b_p$

alors  $uv = a_1a_2...a_nb_1b_2...b_p$

Un prefixe d'une chaine  $w$  est une suite de symboles debutant  $w$ .

Un suffixe de  $w$  est une suite de symboles terminant  $w$ .

$\forall x, y \mid w = x.y$ ,  $x$  est un prefixe de  $w$ ,  $y$  un suffixe.

Une sous-chaine d'une chaine  $w$  est une suite de symboles apparaissant consecutivement dans  $w$ .

Un langage est un ensemble de chaine.

Exemple de langages:

$\{\text{toto}, \text{titi}, \text{tata}\}$

$\{1, 11, 101, 1001\}$

$\{1^n \mid n \geq 0\} = \{e, 1, 11, 111, 1111, 11111, \dots\}$

Nombres binaires impaires:  $\{1, 11, 101, 111, 1001, 1011, \dots\}$

Nombres binaires premiers:  $\{1, 10, 11, 101, 111, 1011, \dots\}$

le Langage vide, note  $\emptyset$ , ne contient aucune chaine (ensemble vide).

Remarque:  $\emptyset \neq \{\epsilon\}$

Le langage plein, note  $\Sigma^*$

l'Union de deux langages  $A$  et  $B$  est le langage, note  $A \cup B$ , compose de toutes les chaines qui apparaissent dans l'un au moins de langages  $A$  ou  $B$ .

LA concatenation de deux langages  $A$  et  $B$  est le langage, note  $A.B$  ou  $AB$ , compose de toutes les chaines formees par une chaine de  $A$  concatenee a une chaine de  $B$ .

$A.B = \{u.v \mid u \in A \text{ ou } v \in B\}$

Proprietes:

Associativite:  $(A.B).C = A.(B.C)$

$\{\epsilon\}$  est un element neutre:  $A.\{\epsilon\} = \{\epsilon\}.A = A$

$\emptyset$  est element absorbant

Distributivite de la concatenation sur l'union:

Puissance d'une langage  $A$   $A^k$  est le langage forme par la concatenation de  $k$  occurrences de  $A$ .

$A^0 = \{\epsilon\}$

$A^1 = A$

Etoile de Kleene (fermeture ou cloture par  $*$ ).

- la fermeture de Kleene d'un langage A est le langage, note  $A^*$   
 $A^* = \bigcup_{i=0}^{\infty} A^i$